

Дистрибутивная семантика. Векторные представления текста

Дистрибутивная семантика

Область лингвистики, которая занимается вычислением степени семантической близости между лингвистическими единицами на основании их распределения (дистрибуции) в больших массивах лингвистических данных (текстовых корпусах). (Википедия)

Вычисление семантической близости

Семантическая близость вычисляется при помощи сравнения векторов слов.

Какие способы получить вектор слова мы уже рассмотрели? В чем их достоинства и недостатки?

Векторные представления слов

- Bag of words (CountVectorizer)
- TF-IDF
- Латентно-семантический анализ


Недостатки:

- Разреженность;
- Проблема отсутствующих и редких слов.

Языковые модели

“You shall know a word by the company it keeps” – [J.R. Firth](#).

Языковые модели моделируют генерацию естественного языка. Это распределения вероятностей на последовательностях слов, которые предсказывают следующее слово на основании контекста.




Word2Vec

Word2Vec


Word2Vec - технология, которая позволяет при помощи глубокого обучения выучивать **эмбединги** слов: векторы фиксированной длины, отражающие смысл слова. Нейросеть обучается предсказывать слово по контексту или контекст по слову.

Word2Vec: архитектуры

- CBOW (Continuous Bag of Words):
предсказание слова
по окружающим его
словам;
- Skip-gram:
предсказание
контекста по слову.



CBOW



Skip-gram


CBOW

text = 'Особую опасность **таил** для Пнина английский язык.'

window_size = 2 (total window span = 5)

input: ['особую', 'опасность', 'для', 'пнина']

output: '**таил**'



CBOW: данные для обучения

text = 'Особую опасность таил для Пнина английский язык.'

Input				Output
особую	опасность	для	пнина	таил
опасность	таил	пнина	английский	для
таил	для	английский	язык	пнина

(на самом деле входные слова все равно подаются в модель по одному)


Skip-gram

text = 'Особую опасность **таил** для Пнина английский язык.'

window_size = 2

input: '**таил**'

output: ['особую', 'опасность', 'для', 'пнина']




Skip-gram: данные для обучения

text = 'Особую опасность таил для Пнина английский язык.'

Input	Output
таил	особую
таил	опасность
таил	для
таил	пнина
для	опасность
для	таил
...	...


Word2Vec: обучение

Задача: мультиклассовая классификация на n классов, где n - размер словаря.




Word2Vec: обучение

Вопрос: что содержат матрицы A и B?



Word2Vec: обучение


Ответ: A и B - это матрицы весов нейросети.



	Матрица A ↘	Нейрон 1 слоя j	Нейрон 2 слоя j	...	Нейрон k слоя j
немолодой	Нейрон 1 слоя i	$\text{вес}_{i1,j1}$	$\text{вес}_{i1,j2}$	...	$\text{вес}_{i1,jk}$
пассажир	Нейрон 2 слоя i	$\text{вес}_{i2,j1}$	$\text{вес}_{i2,j2}$	...	$\text{вес}_{i2,jk}$
...	...	...	...	...	...
таил	Нейрон n слоя i	$\text{вес}_{in,j1}$	$\text{вес}_{in,j2}$	...	$\text{вес}_{in,jk}$

Word2Vec: обучение

Таким образом, 0.46 - это произведение строки матрицы A и столбца матрицы B с порядковым номером n-2, присвоенным в словаре слову “таил”.



Word2Vec: обучение

Задача обучения Word2Vec - оптимизировать веса матриц A и B .

Матрица A представляет вектор слова i как центрального слова, а матрица B - вектор слова i как слова в контексте.

Обе матрицы можно использовать в качестве матриц эмбедингов слов.

Skip-gram with negative sampling

Интуиция 1: вместо того, чтобы предсказывать слова, почему бы не предсказывать вероятности того, что слова окажутся рядом?

Интуиция 2: чтобы создать датасет для этого задания, нужны не только положительные, но и отрицательные примеры.

Цель: упростить задачу и уменьшить вычислительные затраты.

Word 1	Word 2	Probability
таил	особую	1
таил	опасность	1
таил	таил	0
таил	кондуктор	0
для	опасность	1
для	таил	1
...	...	...

Желаемые результаты обучения

Возьмём эмбединг слова “king” из библиотеки GloVe:


```
[ 0.50451 , 0.68607 , -0.59517 , -0.022801, 0.60046 , -0.13498 , -0.08813 , 0.47377 , -0.61798 ,  
-0.31012 , -0.076666, 1.493 , -0.034189, -0.98173 , 0.68229 , 0.81722 , -0.51874 , -0.31503 ,  
-0.55809 , 0.66421 , 0.1961 , -0.13495 , -0.11476 , -0.30344 , 0.41177 , -2.223 , -1.0756 , -1.0783  
 , -0.34354 , 0.33505 , 1.9927 , -0.04234 , -0.64319 , 0.71125 , 0.49159 , 0.16754 , 0.34344 ,  
-0.25663 , -0.8523 , 0.1661 , 0.40102 , 1.1685 , -1.0137 , -0.21585 , -0.15155 , 0.78321 , -0.91241  
 , -1.6106 , -0.64426 , -0.51042 ]
```

И сделаем его heatmap (схему, где большие числа обозначены теплым цветом, а меньшие - холодным):



Желаемые результаты обучения

Сравним эмбединг слова “king” с похожими словами.



Желаемые результаты обучения

Вектора эмбеддингов
можно вычитать и
складывать, и результаты
этих операций будут
интерпретируемы.



Желаемые результаты обучения

Пример из оригинальной статьи:
если вычесть из вектора “China”
вектор “Beijing”, а потом к
результатирующему вектору
прибавить вектор “Russia”,
можно получить вектор, близкий
к “Moscow”.




Figure 2: Two-dimensional PCA projection of the 1000-dimensional Skip-gram vectors of countries and their capital cities. The figure illustrates ability of the model to automatically organize concepts and learn implicitly the relationships between them, as during the training we did not provide any supervised information about what a capital city means.

Word2Vec: плюсы и минусы

- + Вектора имеют смысл;
- + Можно установить любую размерность;
- + Модель можно дообучать на новых документах.
- Неоптимальные эмбединги для редких слов;
- Для однокоренных слов эмбединги разные;
- Нельзя добавить новые вектора слов без обучения заново.

За пределами Word2Vec

Другие эмбеддинги

- Fasttext;
- GloVe;
- ELMO;
- BERT...

Fasttext

- Skip-gram с негативным семплированием;
- К основной модели добавлена модель с использованием символьных n-грамм с n от 3 до 6 символов и самого слова:



котичек = <ко, кот, оти, тич, иче, чек, ек>; <котичек>

Токены < и > сигнализируют начало и конец слова, чтобы модель отделяла аффиксы от частей другого слова.

- + Можно не беспокоиться о редких и незнакомых словах;
- Словарь модели всё ещё очень большой.


Global Vectors (GloVe)

GloVe использует не только локальные контексты, но и глобальную (рассчитанную на всем корпусе) статистику совместной встречаемости слов.



ELMO

ELMO (Embeddings from Language Model) - это рекуррентная нейросеть, принимающая во внимание контекст слова при обучении эмбеддингов.



Картинка:

https://neerc.ifmo.ru/wiki/index.php?title=%D0%92%D0%B5%D0%BA%D1%82%D0%BE%D1%80%D0%BD%D0%BE%D0%B5_%D0%BF%D1%80%D0%B5%D0%B4%D1%81%D1%82%D0%B0%D0%B2%D0%BB%D0%B5%D0%BD%D0%B8%D0%B5_%D1%81%D0%BB%D0%BE%D0%B2

Не просто слова: эмбе́ддинги
последовательностей

Эмбеддинги последовательностей слов


Что можно сделать, чтобы получить эмбеддинг предложения или текста?

- Складывать эмбеддинги слов;
- Предсказывать порядок следования предложений;
- Предсказывать слова между двумя предложениями;
- Предсказывать, может ли предложение А идти после предложения В;
- Обучать модель на сложные лингвистические задачи (например, перевод) и доставать эмбеддинги из неё;
- ...

Doc2Vec

- Distributed Memory version of Paragraph Vector (PV-DM)


Идея: для каждого абзаца добавлять обучаемый вектор, дополняя модель CBOW. Таким образом, модель как бы выучивает тему параграфа.



Doc2Vec

- Distributed Bag of Words version of Paragraph Vector (PV-DBOW)

Идея: аналогично модели Skip-gram: слова параграфа предсказываются по вектору параграфа.



SentenceTransformers

SentenceTransformers - библиотека для работы с эмбедингами предложений, полученными из трансформера BERT.

Библиотека включает множество моделей:

https://sbert.net/docs/pretrained_models.html, некоторые из которых лучше подходят для семантического поиска (выдачи релевантных предложений в ответ на запрос), а другие - для сопоставления векторов предложений.

Применение и оценка эмбеддингов

Где используются эмбединги и как оценить их качество?

Эмбединги могут использоваться везде, где нужно представить слово как вектор - т.е., в любой модели машинного обучения, в которую подаются тексты.

Поэтому качество различных эмбедингов можно сравнивать, используя их в составе других моделей для решения различных задач. При этом архитектура модели, кроме эмбедингов, не меняется.

Где используются эмбединги и как оценить их качество?

Extrinsic evaluation:

- Классификация текстов;
- Выявление логических связей (entailment);
- Поиск парафраз;
- Поиск подписи для картинки;
- ...

Intrinsic evaluation (на специальных датасетах-бенчмарках для оценки эмбедингов):

- Семантическая близость слов;
- Синтаксическая близость;
- Поиск аналогий;
- ...

Практика:

https://colab.research.google.com/drive/1oZKsNhNxANeM4p4eN3jT2yc_DGhpi4BU?usp=sharing

Источники

- Word2Vec:
 - <https://youtu.be/WbtQzAvhnRI?si=MW9cNKCKJ9g0Y4Pg>
 - <https://jalammar.github.io/illustrated-word2vec/> (перевод: <https://habr.com/ru/articles/446530/>)
 - Борис Орехов про анализ русской литературы с помощью gensim: <https://habr.com/ru/articles/326380/>
- Остальные модели:
 - <https://youtu.be/RKGi26Yk-5A?si=4LQtBZd9ShIMgYIZ>
 - https://neerc.ifmo.ru/wiki/index.php?title=%D0%92%D0%B5%D0%BA%D1%82%D0%BE%D1%80%D0%BD%D0%BE%D0%B5_%D0%BF%D1%80%D0%B5%D0%B4%D1%81%D1%82%D0%B0%D0%B2%D0%BB%D0%B5%D0%BD%D0%B8%D0%B5_%D1%81%D0%BB%D0%BE%D0%B2
 - https://radimrehurek.com/gensim/auto_examples/tutorials/run_doc2vec_lee.html
 - <https://arxiv.org/pdf/1803.05449>